

Perbandingan Metode KNN dan Naïve Bayes dalam Deteksi Tingkat Stres Berdasarkan Ekspresi Wajah

Malik Fajar Alamsyah ¹, Ardi Wijaya ²

^{1,2} Program studi Teknik Informatika, Fakultas Teknik, Universitas Muhammadiyah Bengkulu, Bengkulu, 38119, Indonesia

Info Artikel

Riwayat Artikel:

Received 2025-02-25

Revised 2025-04-24

Accepted 2025-04-30

Corresponding Author:

Ardi Wijaya

Email: ardiwijaya@umb.ac.id



This is an open access article under the [CC BY 4.0](https://creativecommons.org/licenses/by/4.0/) license.

Abstract – Stress is a feeling in which a person feels under pressure, overwhelmed, and has difficulty in dealing with a problem. Stress can be caused by various factors, such as academic pressure, work, personal problems, or social environment. If not addressed immediately, stress can have adverse effects on an individual's health, such as causing high blood pressure, heart disease, sleep disturbances, and a decreased immune system, which makes a person more vulnerable to various diseases. Therefore, monitoring stress levels is very important to prevent more serious negative impacts. Generally, stress detection is done through consultation with a psychologist, but this method has a subjective nature and requires a lot of time and money. Therefore, this research develops a computer vision-based stress detection system using OpenCV and Dlib, with K-Nearest Neighbors and Naïve Bayes algorithms. The data of 500 samples is divided into 80% training data and 20% test data. Features were extracted, and stress was classified into three levels: low, medium and high. Evaluation using k-fold cross-validation ($n_split=10$, $random_state=42$) based on accuracy, precision, recall, and F1-score. The results showed that K-Nearest Neighbors with $k=5$ excelled with 74% accuracy, 73% precision, 73% recall, and 73% F1-score. Meanwhile, Naïve Bayes only achieved 52% accuracy, 51% precision, 48% recall, and 41% F1-score. This shows that KNN is more effective in stress level classification. However, the accuracy of the model is still limited due to the small amount of training data. Parameter optimization and dataset addition are required to improve the overall system performance.

Keywords: OpenCV; Dlib; KNN; Naïve Bayes; Image Processing.

Abstrak – Stres merupakan perasaan di mana seseorang merasa dalam tekanan, kewalahan, serta mengalami kesulitan dalam menghadapi suatu permasalahan. Stres dapat disebabkan oleh berbagai faktor, seperti tekanan akademik, pekerjaan, masalah pribadi, atau lingkungan sosial. Jika tidak segera ditangani, stres dapat berdampak buruk pada kesehatan individu, seperti menyebabkan tekanan darah tinggi, penyakit jantung, gangguan tidur, dan menurunnya sistem kekebalan tubuh, yang membuat seseorang lebih rentan terhadap berbagai penyakit. Oleh karena itu, pemantauan tingkat stres menjadi hal yang sangat penting untuk mencegah dampak negatif yang lebih serius. Umumnya, deteksi stres dilakukan melalui konsultasi dengan psikolog, tetapi metode ini memiliki sifat subjektif dan membutuhkan waktu serta biaya yang tidak sedikit. Oleh karena itu, Penelitian ini mengembangkan sistem deteksi stres berbasis computer vision menggunakan OpenCV dan Dlib, dengan algoritma K-Nearest Neighbors dan Naïve Bayes. Data sebanyak 500 sampel dibagi menjadi 80% data latih dan 20% data uji. Fitur diekstraksi, lalu stres diklasifikasikan ke dalam tiga tingkat: rendah, sedang, dan tinggi. Evaluasi menggunakan k-fold cross-validation ($n_split=10$, $random_state=42$) berdasarkan akurasi, precision, recall, dan F1-score. Hasil menunjukkan bahwa K-Nearest Neighbors dengan $k=5$ unggul dengan akurasi 74%, precision 73%, recall 73%, dan F1-score 73%. Sementara itu, Naïve Bayes hanya mencapai akurasi 52%, precision 51%, recall 48%, dan F1-score 41%. Ini menunjukkan bahwa KNN lebih efektif dalam klasifikasi tingkat stres. Namun, akurasi model masih terbatas karena jumlah data latih yang sedikit. Diperlukan optimasi parameter dan penambahan dataset untuk meningkatkan kinerja sistem secara keseluruhan.

Kata Kunci: OpenCV, Dlib, KNN, Naïve Bayes, Pemrosesan Gambar.

I. PENDAHULUAN

Di Indonesia, sekitar 15,5 juta remaja usia 10–17 tahun menghadapi masalah kesehatan mental, termasuk stres. Pada 2022, survei I-NAMHS mencatat 34,9% remaja dalam 12 bulan terakhir mengalami masalah kesehatan mental dan 2,45 juta atau 5,5% remaja memiliki setidaknya salah satu gangguan mental [1]. Tahun berikutnya, Survei Kesehatan Indonesia pada 2023 menunjukkan remaja usia 15–24 tahun menjadi kelompok dengan gejala depresi tertinggi. Sebanyak 1% mengalami depresi, 3,7% mengalami gangguan kecemasan, 0,9% menunjukkan gejala PTSD, dan 0,5% mengalami ADHD [2]. Stres memiliki pengaruh secara signifikan terhadap kesehatan secara keseluruhan. Namun, banyak orang cenderung mengabaikan stres, bahkan tidak menyadari tingkat stres yang mereka alami, padahal stres merupakan faktor pemicu berbagai penyakit [3]. Stres dapat menyebabkan naiknya tekanan darah dan turut berperan dalam berbagai masalah kesehatan lainnya. Pengelolaan stres sangat penting untuk menjaga kesehatan tubuh [4]. Deteksi tingkat stres biasanya dilakukan dengan wawancara, yang mana hal ini sangat bergantung pada pengakuan individu terhadap kondisi psikologis mereka [5]. Namun, cara ini tidak selalu efektif karena faktor-faktor emosional dan sosial yang dapat

mempengaruhi pengakuan seseorang terhadap stres yang mereka rasakan. Oleh karena itu, pendekatan dengan memanfaatkan teknologi memungkinkan untuk melakukan deteksi secara otomatis dan akurat, tanpa ketergantungan pada pengakuan individu itu sendiri. Selain itu metode ini mampu menghasilkan output dengan lebih cepat dan efisien. [6].

Teknologi yang dapat digunakan dalam mendeteksi wajah manusia, ialah pemanfaatan computer vision yang dapat digunakan untuk memproses dan mengidentifikasi gambar seperti cara kerja manusia, serta memberikan output yang sesuai [7]. Melihat serta mengenali sebuah citra dengan tingkat akurasi setara atau melebihi kemampuan pengelihat manusia asli adalah kemampuan dari computer vision itu sendiri [8]. Kemudian, dengan menggunakan OpenCV yang merupakan library terbuka yang menyediakan 2500 algoritma, sehingga hal ini dapat mengoptimalkan penggunaan computer vision dan machine learning yang akan digunakan. Lalu, fungsi utama dari OpenCV itu sendiri adalah untuk mendeteksi wajah, pengenalan wajah, objek, dan lain-lain [9]. Setelah itu, Dlib yang merupakan pustaka open source digabungkan untuk meningkatkan dan membantu dalam mendeteksi. Dlib dirancang untuk pengolahan citra, salah satunya untuk pengenalan wajah, dlib dibuat dengan deep learning sehingga memiliki tingkat akurasi 99,38% [10]. Dalam penerapan machine learning pada computer vision, OpenCV dan Dlib sering digunakan secara bersamaan untuk meningkatkan kinerja dalam berbagai tugas pemrosesan citra. Machine learning memungkinkan model untuk dilatih menggunakan kumpulan data gambar atau video sehingga dapat mengenali pola tertentu. Beberapa metode yang umum digunakan dalam klasifikasi dan pengenalan pola adalah *K-Nearest Neighbors* dan *Naïve Bayes*. Metode *K-Nearest Neighbors* bekerja dengan membandingkan sampel baru dengan data yang telah dilatih berdasarkan kedekatan jaraknya dalam ruang fitur. Algoritma ini sederhana namun efektif dalam pengenalan pola, termasuk klasifikasi gambar. Sementara itu, *Naïve Bayes* merupakan metode berbasis probabilitas yang mengasumsikan bahwa setiap fitur dalam data bersifat independen, sehingga dapat digunakan untuk pengklasifikasian cepat pada dataset besar.

Pada penelitian Fitra, dkk [11] melakukan perbandingan untuk mendeteksi ekspresi wajah dengan menerapkan tiga metode berbeda, yaitu *Extreme Learning Machine*, *Support Vector Machine*, dan *K-Nearest Neighbors*, menggunakan 5-fold *cross-validation* dengan pembagian 80% data latih dan 20% data uji. Hasil eksperimen menunjukkan bahwa ELM memiliki akurasi tertinggi sebesar 0,76, diikuti oleh SVM dengan 0,69, dan KNN hanya mencapai 0,55. Parameter terbaik yang digunakan dalam penelitian ini adalah 40 hidden neuron untuk ELM, nilai regulasi $C = 10^5$ dan 200 iterasi untuk SVM, serta $k = 3$ tetangga untuk KNN. Perbedaan akurasi ini menunjukkan bahwa pemilihan algoritma dan parameter yang tepat sangat memengaruhi kinerja model. ELM unggul dalam kecepatan dan kemampuan generalisasi, sementara SVM menunjukkan performa yang baik dengan parameter yang sesuai. Di sisi lain, akurasi KNN yang lebih rendah kemungkinan disebabkan oleh ketergantungannya pada distribusi data dan jumlah tetangga yang digunakan dalam klasifikasi, sehingga pemilihan parameter yang lebih optimal diperlukan untuk meningkatkan hasilnya.

Selanjutnya penelitian Rifki Kosasih [12] metode KNN memiliki tingkat akurasi lebih tinggi dibandingkan *Naïve Bayes* dalam klasifikasi ekspresi wajah. Dengan menggunakan fitur isomap, KNN dengan $k = 2$ mencapai akurasi 87,5%, sedangkan *Naïve Bayes* hanya mencapai 50%. Perbedaan ini kemungkinan besar terjadi karena jumlah data yang digunakan cukup terbatas, yaitu hanya 24 sampel wajah, serta pemilihan nilai k yang masih kecil. Melihat hal ini, dalam penelitian ini berencana meningkatkan nilai k menjadi 5 untuk melihat apakah akurasi model bisa lebih optimal dengan mempertimbangkan lebih banyak tetangga dalam klasifikasi. Meskipun begitu, tantangan dalam meningkatkan akurasi tetap ada, terutama karena jumlah data yang terbatas masih menjadi faktor utama yang memengaruhi kinerja algoritma.

Penelitian ini bertujuan untuk mengembangkan suatu sistem yang memanfaatkan teknologi OpenCV untuk menangkap dan memproses gambar wajah, serta dlib untuk mendeteksi titik-titik penting pada wajah yang menggambarkan ekspresi emosional seseorang. Titik-titik tersebut, seperti letak mata, alis, hidung, dan mulut, kemudian diekstraksi menjadi data numerik yang dikenal sebagai fitur wajah. Fitur-fitur ini mencerminkan perubahan ekspresi yang berkaitan dengan tingkat stres. Setelah proses ekstraksi, data yang dihasilkan terdiri dari koordinat titik-titik wajah serta jarak antar titik-titik tertentu yang menggambarkan ekspresi seseorang. Kumpulan angka ini disebut sebagai fitur wajah dan menjadi input utama dalam proses klasifikasi tingkat stres menggunakan metode *K-Nearest Neighbors* dan *Naïve Bayes*. Data fitur wajah ini akan digunakan sebagai dataset untuk metode machine learning tersebut. Dalam penelitian ini menggunakan 500 dataset yang digunakan untuk melatih model machine learning tersebut.

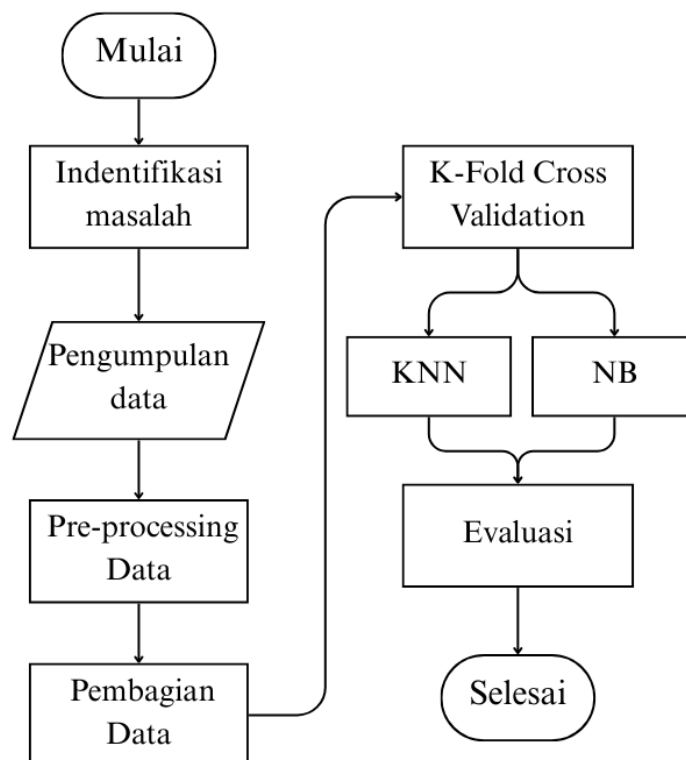
Dalam pengolahan data tingkat stres, metode *Naive Bayes* dan *K-Nearest Neighbors* menjadi pilihan yang tepat karena keunggulannya dalam mengelola data. *Naive Bayes*, dengan distribusi *Gaussian*, efektif digunakan pada data numerik yang diasumsikan mengikuti distribusi normal. Metode ini menghitung probabilitas tiap kelas dengan cepat dan efisien berkat asumsi independensi antar fitur, sehingga tetap akurat meski data sederhana. Sementara itu, *K-Nearest Neighbors* bekerja dengan mengukur jarak antar data berdasarkan kelas mayoritas tetangga terdekat. Metode ini tidak memerlukan pelatihan model yang rumit dan mudah beradaptasi dengan data baru. Dengan kelebihan masing-masing, kedua metode ini mampu memberikan hasil klasifikasi tingkat stres yang praktis dan efektif.

Lalu, metode *K-Nearest Neighbors* bekerja dengan membandingkan fitur wajah baru dengan data latih yang sudah diketahui tingkat stresnya. Ia menghitung jarak antar wajah dan menentukan tingkat stres berdasarkan mayoritas label dari tetangga terdekat. Sementara itu, *Naïve Bayes* menggunakan pendekatan probabilistik, menghitung kemungkinan seseorang mengalami stres berdasarkan distribusi statistik dari fitur wajah, dengan asumsi bahwa tiap fitur bersifat independen. Gaussian *Naïve Bayes* sering digunakan karena sesuai untuk data numerik yang mengikuti distribusi normal. Kedua metode ini memanfaatkan data numerik hasil ekstraksi fitur wajah untuk mengenali tingkat stres. Perbedaannya terletak pada pengambilan keputusan: *K-Nearest Neighbors* berdasarkan kemiripan data, sedangkan *Naïve Bayes* berdasarkan probabilitas. Kombinasi keduanya bisa menjadi pilihan untuk menciptakan sistem deteksi stres yang akurat dan efisien.

Penerapan sistem ini memungkinkan deteksi stres secara otomatis dan objektif tanpa wawancara atau kuesioner. Di sekolah dan universitas, guru atau dosen dapat lebih cepat mengetahui tekanan yang dialami siswa. Di dunia kerja, perusahaan bisa memantau kesehatan mental karyawan untuk meningkatkan produktivitas. Dalam bidang medis, sistem ini dapat membantu tenaga kesehatan dalam penilaian kondisi mental pasien secara lebih cepat dan tepat. Secara keseluruhan, penelitian ini tidak hanya menghadirkan inovasi teknologi dalam deteksi stres berbasis wajah dan kecerdasan buatan, tetapi juga berpotensi meningkatkan perhatian terhadap kesehatan mental di berbagai sektor kehidupan.

II. METODE

Dalam menyelesaikan penelitian ini, dilakukan beberapa tahapan yang meliputi identifikasi masalah, pengumpulan data, *pre-processing* data, pembagian data, perancangan model, pelatihan model, dan evaluasi. Setiap tahapan memiliki peran penting dalam memastikan sistem yang dikembangkan dapat berfungsi dengan optimal. Tahapan penelitian ini dapat dilihat pada Gambar 1.



Gambar 1. Metode penelitian

A. Pengumpulan Data

Penelitian ini memanfaatkan teknologi computer vision untuk perekaman dan analisis data secara *real-time* menggunakan bahasa pemrograman Python, dengan pustaka utama OpenCV dan Dlib yang berperan penting dalam pemrosesan citra serta analisis berbasis machine learning. Python dipilih karena kemudahan penggunaannya dan ekosistem pustaka yang luas, memungkinkan pengembangan aplikasi computer vision secara efisien. OpenCV, sebagai pustaka open-source, menangani pengambilan gambar melalui webcam, pra-pemrosesan citra, serta deteksi dan pelacakan objek secara *real-time* dengan performa tinggi, efektif bahkan pada perangkat dengan keterbatasan sumber daya. Sementara itu, Dlib digunakan karena kecepatannya dan efisiensinya dalam mendeteksi serta melacak fitur wajah dengan akurasi tinggi, terutama melalui fitur facial landmark

detection yang mengidentifikasi 68 titik fitur pada wajah, termasuk mata, hidung, mulut, dan kontur wajah. Penggunaan *facial landmark detection* ini penting dalam penelitian untuk menganalisis ekspresi dan pergerakan wajah secara lebih akurat. Kombinasi OpenCV dan Dlib memungkinkan perekaman yang lebih alami, karena remaja sebagai subjek penelitian tidak diberikan instruksi khusus, sehingga data yang diperoleh mencerminkan kondisi sebenarnya dan meningkatkan akurasi analisis. Dengan OpenCV yang menangani pemrosesan citra dan video serta Dlib yang menyediakan algoritma deteksi dan pelacakan wajah berbasis *facial landmark*, sistem ini beroperasi secara optimal dalam kondisi *real-time*, menjadi solusi yang ringan, cepat, dan efektif untuk analisis berbasis *computer vision*. Pemilihan Dlib karena kesederhanaan dan kecepatan, hal ini membuatnya menjadi opsi yang tepat untuk pengembangan sistem yang cepat dan ringan dalam kondisi sumber daya terbatas. [13]. Sehingga dengan menggunakan dua Pustaka tersebut, pemrograman computer vision secara *real-time* melalui webcam dapat dilakukan secara optimal, karena OpenCV menangani pemrosesan gambar dan video, sementara dlib menyediakan algoritma machine learning untuk deteksi wajah, dan pelacakan [14].

Dalam memastikan kualitas data, penelitian ini melibatkan 45 remaja dari latar belakang yang berbeda. Dalam prosesnya, setiap remaja akan diminta untuk menunjukkan berbagai ekspresi wajah secara alami, tanpa batasan jumlah atau jenis ekspresi tertentu. Sehingga akan diperoleh variasi data yang lebih banyak, yang kemudian digunakan dalam analisis tingkat stres. Dari seluruh data yang diperoleh, sebanyak 135 sampel akan diambil dan digunakan dalam penelitian ini.

Perekaman dilakukan dalam kondisi yang mencerminkan situasi sehari-hari guna memperoleh hasil yang lebih akurat. Selama proses tersebut, aspek pencahayaan, sudut pengambilan gambar, dan resolusi turut diperhatikan demi memastikan kualitas data yang optimal [15]. Untuk memastikan kualitas serta konsistensi data yang dikumpulkan, setiap gambar disimpan dalam format JPG. Resolusi gambar disesuaikan agar tetap cukup tinggi untuk ekstraksi fitur yang akurat, namun tetap efisien dalam hal penyimpanan dan pemrosesan lebih lanjut.

B. Pre-processing Data

Setelah data dikumpulkan dan disimpan dalam file Excel, selanjutnya dilakukan pre-processing, yaitu proses persiapan data sebelum diproses untuk penelitian ini. Dalam proses ini meliputi pembersihan data, transformasi data, dan normalisasi data. Kemudian, Informasi yang tidak jelas dan tidak relevan bagi penelitian akan dihapus dengan berbagai langkah dalam menghasilkan data yang baik untuk dilakukan analisis.

C. Pembagian Data

Setelah dilakukannya tahap pre-processing data, diperoleh sebanyak 500 sampel yang dikategorikan ke dalam tiga tingkat stres, yaitu low stress, medium stress, dan high stress. Untuk memastikan model machine learning dapat berfungsi dengan optimal dan menghasilkan prediksi yang akurat, dataset kemudian dibagi menjadi dua bagian. Sebanyak 80% dari total 500 sampel akan digunakan sebagai data latih. Sisanya yaitu 20% akan dijadikan sebagai data uji untuk mengevaluasi performa model machine learning dalam mengklasifikasikan tingkat stres berdasarkan sampel yang belum pernah dipelajari sebelumnya [16].

D. K-Fold Cross Validation

K-Fold Cross Validation merupakan salah satu Teknik validasi silang yang umum digunakan untuk mengevaluasi kinerja model machine learning. Teknik ini bekerja dengan membagi dataset menjadi k subset atau fold dengan ukuran sama, dimana setiap fold akan secara bergiliran digunakan sebagai data uji, sementara sisa fold akan digunakan sebagai data latih [17]. Penggunaan metode ini akan menghasilkan performa model yang lebih stabil dan akurat, serta akan meminimalisasi *overfitting* dengan mengevaluasi model pada berbagai kombinasi data latih dan data uji [18].


E. Klasifikasi

Klasifikasi merupakan proses suatu objek atau data dikelompokkan ke dalam kategori atau kelas tertentu berdasarkan karakteristik yang dimiliki. Tujuannya agar mempermudah objek atau data yang belum diketahui kelasnya dapat dikelompokkan berdasarkan kategori. Proses yang akan dilakukan pada klasifikasi ada 2 proses, yaitu proses latih dengan membangun model berdasarkan data latih. Proses uji dilakukan dengan pengujian terhadap data latih dengan data uji [19]. *Machine learning* adalah salah satu bidang dalam kecerdasan buatan yang berfungsi untuk melatih program komputer. [20]. Program tersebut belajar dari kumpulan data yang luas dengan menerapkan berbagai algoritma dan metode statistik. Teknologi ini memungkinkan analisis data untuk mengidentifikasi pola berdasarkan informasi sebelumnya, sehingga teknologi ini dapat dimanfaatkan untuk memprediksi kejadian di masa mendatang. Beberapa teknik machine learning bekerja dengan set data yang berukuran besar, sehingga membuatnya semakin akurat. Dalam penelitian ini digunakannya 2 algoritma yang akan di bandingkan tingkat akurasi, yaitu *Naïve Bayes* dan *K-Nearest Neighbors*.

Naïve Bayes bekerja dengan menghitung probabilitas suatu kelas berdasarkan hubungan antar fitur dalam dataset. Algoritma ini mengasumsikan bahwa setiap fitur bersifat independen, sehingga perhitungannya menjadi lebih sederhana dan efisien. Sehingga, *Gaussian Naïve* diterapkan karena informasi yang dianalisis berbentuk

numerik dan diasumsikan mengikuti distribusi normal [21]. Model ini menerima input berupa fitur-fitur yang telah diekstraksi dari data terkait tingkat stres. Selanjutnya, setiap kelas (*low stress*, *medium stress*, *high stress*) dihitung probabilitasnya berdasarkan distribusi data yang tersedia. Hasil akhirnya berupa prediksi tingkat stres seseorang berdasarkan nilai probabilitas tertinggi di antara tiga kategori.

Berbeda dengan *Naïve Bayes*, KNN memiliki cara kerja dengan mencari tetangga terdekat yang disimbolkan dengan K, dari suatu data baru berdasarkan perhitungan jarak dalam ruang fitur. Pemilihan nilai K yang optimal menjadi faktor penting dalam menentukan akurasi model. Model ini menerima input berupa fitur-fitur terkait tingkat stres dan metode ini mengukur jarak antara data baru dengan seluruh data latih berdasarkan tetangga terdekat. Setelah itu, nilai K dipilih berdasarkan eksperimen guna mendapatkan hasil klasifikasi terbaik. Kelas tingkat stres ditentukan berdasarkan mayoritas kelas dari K tetangga terdekat [22].



Gambar 2. Grafik Nilai K

Pada penelitian sebelumnya, pemilihan nilai K sebesar 2 dan 3 belum memberikan hasil akurasi yang optimal. Hal ini terlihat dari performa model KNN yang masih kurang maksimal dalam melakukan klasifikasi. Berdasarkan hasil pengujian yang ditampilkan pada Gambar 2, diketahui bahwa ketika model KNN dilatih dengan nilai K = 5, akurasi mencapai tingkat tertinggi dibandingkan dengan nilai K lainnya. Oleh karena itu, dalam penelitian ini akan digunakan nilai K = 5 untuk model KNN, dengan harapan dapat meningkatkan performa dan keakuratan model dalam melakukan klasifikasi.

F. Evaluasi

Setelah pengujian, data akan dievaluasi untuk mengukur keakuratan model dengan melihat nilai *precision*, *recall*, *F1-score*, dan terutama akurasi. Evaluasi ini bertujuan untuk memahami seberapa baik model dalam membuat prediksi atau mengklasifikasikan data dengan benar. Untuk mengevaluasi sejauh mana model dapat mengklasifikasikan tingkat stres dengan benar, akurasi menjadi metrik utama yang digunakan Formula 1.

$$\text{Akurasi} = \frac{TP + TN}{(TP + TN + FP + FN)} \quad (1)$$

Presisi mengukur seberapa akurat model dalam mengidentifikasi individu dengan tingkat stres tertentu (*low*, *medium*, atau *high*) dibandingkan dengan seluruh individu yang diprediksi berada dalam kategori tersebut. Presisi dihitung dengan membandingkan jumlah *True Positive* dengan total jumlah *True Positive* dan *False Positive*. Artinya, presisi mengukur seberapa banyak prediksi positif yang benar dibandingkan dengan keseluruhan prediksi yang dikategorikan sebagai positif Formula 2.

$$\text{Presisi} = \frac{TP}{(TP + FP)} \quad (2)$$

Recall menunjukkan seberapa baik model dalam mengidentifikasi individu yang benar-benar mengalami tingkat stres tertentu. Nilai recall diperoleh dengan membagi jumlah *True Positive* dengan total *True Positive* dan *False Negative*, sehingga mencerminkan kemampuan model dalam mendeteksi semua kasus positif secara

akurat Formula 3. *Recall* sangat penting untuk memastikan bahwa individu yang memiliki stres tinggi tidak terlewat dalam proses klasifikasi, begitu juga dengan kategori stres rendah dan sedang.

$$\text{Recall} = \frac{TP}{(TP + FN)} \quad (3)$$

F1-score digunakan untuk menyeimbangkan presisi dan *recall* dalam setiap kategori stres (*low*, *medium*, *high*), terutama jika distribusi data dalam setiap kategori tidak merata. Nilainya dihitung sebagai rata-rata harmonik dari presisi dan recall Formula 4. *F1-score* memberikan pemahaman yang lebih menyeluruh mengenai kinerja model dalam mengklasifikasikan tingkat stres.

$$F1 - score = 2 \frac{\text{Precision} * \text{Recall}}{\text{Precision} + \text{Recall}} \quad (4)$$

Keempat metode evaluasi tersebut akan digunakan sebagai dasar untuk menilai performa masing-masing model klasifikasi secara terpisah, dengan fokus pada model *K-Nearest Neighbors* dan *Naive Bayes*. Evaluasi ini dirancang untuk menganalisis sejauh mana kedua algoritma mampu mengklasifikasikan tingkat stres dengan akurat. Dengan membandingkan hasil yang diperoleh dari setiap model, penelitian ini berupaya mengidentifikasi algoritma yang memberikan performa terbaik dalam mendeteksi dan mengklasifikasikan tingkat stres.

III. HASIL DAN PEMBAHASAN

Pada penelitian ini, menggunakan dua metode *machine learning*, yaitu *K-Nearest Neighbors* dan *Naive Bayes* digunakan untuk mendeteksi tingkat stres berdasarkan fitur yang diekstraksi dari data. Setiap model yang dikembangkan menggunakan data sampel yang sama dalam pengukuran tingkat akurasi, *precision*, *recall* dan *F1-score*.

A. Pengolahan

Pengumpulan data yang dilakukan menghasilkan 500 sampel data yang terbagi ke dalam tiga kategori, yaitu tingkat high stres, medium stres, low stres, yang dapat dilihat pada gambar. Setelah data terkumpul, gambar-gambar tersebut akan diekstraksi untuk memperoleh fitur-fitur yang diinginkan, yang kemudian akan digunakan sebagai data.



Gambar 2. (a) low stres, (b) medium stres dan (c) high stres

Data yang dikumpulkan dalam penelitian ini akan dibagi menjadi dua bagian utama, yaitu data latih dan data uji, sebagaimana tercantum dalam Tabel 1 Dataset. Data latih yang digunakan akan sebanyak 400 sampel data. Data latih akan digunakan dalam melatih model untuk membangun dan mengembangkan model machine learning yang digunakan. Lalu, 100 sisa sampel data akan dijadikan data uji. Data Uji digunakan untuk mengevaluasi kinerja model yang telah dilatih. Pembagian data ini dilakukan dengan mempertimbangkan proporsi yang sesuai agar model dapat belajar dengan baik tanpa mengalami *overfitting*. Selain itu, fitur yang digunakan dalam Tabel 1 agar hasil pengujian dapat mencerminkan performa model secara akurat.


TABEL 1
DATASET

No	EAR	MAR	Pupil	Nose	Chin	Level
1	0.2575	0.9553	71.65	30.15	21.12	High Stress
2	0.2782	0.9549	59.52	25.50	15.96	High Stress
3	0.1788	0.8876	60.17	32.02	26.17	High Stress
4	0.2926	0.3354	43.19	24.19	29.61	High Stress
5	0.2080	0.8913	52.33	24.00	20.22	High Stress
...
151	0.2560	0.9616	75.81	30.02	20.62	Medium Stress

152	0.3224	0.7496	66.73	33.00	21.54	Medium Stress
153	0.1893	0.9917	61.73	26.48	31.26	Medium Stress
154	0.1869	0.6925	55.70	24.19	24.19	Medium Stress
155	0.2816	0.9660	52.50	23.02	24.08	Medium Stress
...
496	0.2081	0.9536	69.00	34.00	25.95	Low Stress
497	0.2041	0.9291	69.41	34.01	27.56	Low Stress
498	0.2075	0.9754	69.42	34.01	25.65	Low Stress
499	0.2106	0.9527	70.21	34.01	26.65	Low Stress
500	0.3333	0.8848	60.82	27.07	9.28	Low Stress

B. Hasil *K-Nearest Neighbors*

Berikut adalah hasil yang didapatkan dengan menggunakan algoritma *K-Nearest Neighbors* dengan nilai $K = 5$, parameter `random_state = 42`, dan `n_split = 10` pada teknik *k-fold cross-validation*. Model ini mengklasifikasikan data berdasarkan kedekatan dengan lima tetangga terdekat, di mana setiap sampel diuji dengan membandingkannya terhadap data latih terdekat.



Gambar 3. Confusion Matrix *K-Nearest Neighbors*

Pada gambar 3 terlihat bagaimana model *K-Nearest Neighbors* dengan $K = 5$ bekerja dalam mengklasifikasikan tingkat stres. Hasilnya cukup baik, terutama pada kategori High Stress, di mana model berhasil mengidentifikasi 29 data dengan benar. Ini menunjukkan bahwa model cukup baik dalam mengenali individu dengan tingkat stres tinggi. Namun, pada kategori medium Stress, hasilnya sedikit lebih bervariasi. Dari total data, 17 berhasil diklasifikasikan dengan benar, tetapi ada 6 data yang salah terdeteksi sebagai High Stress dan 3 data yang malah masuk ke kategori Low Stress. Hal ini menunjukkan bahwa model masih mengalami kesulitan dalam membedakan antara tingkat stres rendah High dan Low. Pada kategori Low Stress, di mana model mampu mengklasifikasikan 28 data dengan benar, menunjukan hasil yang cukup baik. Secara keseluruhan, model KNN sudah cukup baik dalam mengidentifikasi High dan Low stres, tetapi masih perlu perbaikan dalam membedakan Medium stres. Mungkin dengan mengoptimalkan pemilihan fitur atau menyesuaikan parameter K , model ini bisa bekerja lebih akurat di semua kategori.

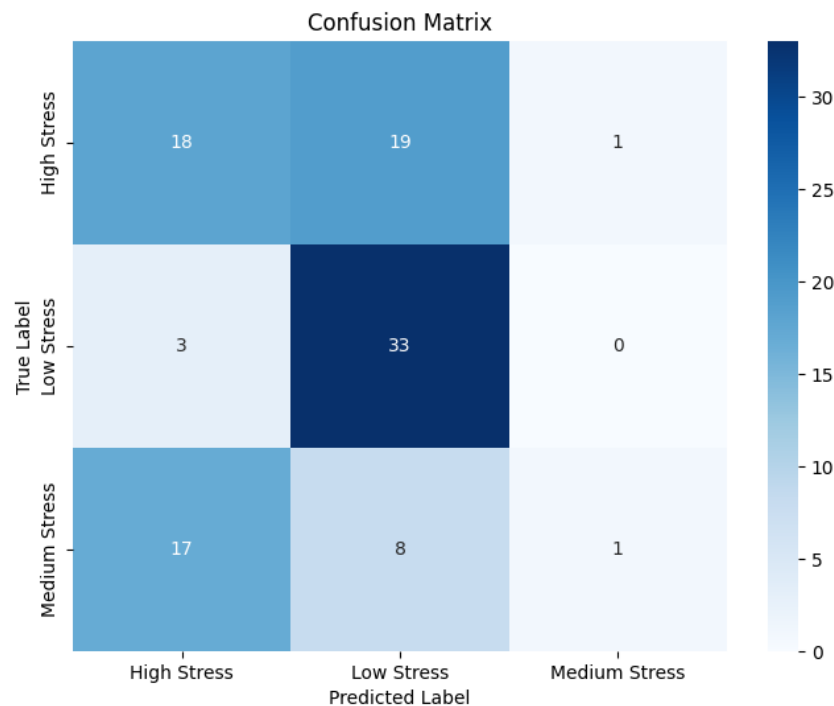
	precision	recall	f1-score	support
0	0.74	0.76	0.75	38
1	0.78	0.78	0.78	36
2	0.68	0.65	0.67	26
accuracy			0.74	100
macro avg	0.73	0.73	0.73	100
weighted avg	0.74	0.74	0.74	100

Gambar 4. Hasil Akurasi Algoritma *K-Nearest Neighbors*

Pada gambar 4 dapat dilihat tingkat akurasi yang didapatkan sebesar 74%, precision 73%, recall 73%, f1-score 73%. Nilai akurasi ini menunjukkan bahwa model mampu mengklasifikasikan data dengan benar, dengan hasil sebesar 74% dari seluruh sampel yang diuji.

C. Hasil *Naïve Bayes*

Selanjutnya hasil yang didapatkan dengan menggunakan algoritma *Naïve Bayes*. Model ini mengklasifikasikan data berdasarkan probabilitas tertinggi, dengan cara membandingkan setiap sampel terhadap pola-pola yang telah dipelajari dari data latih sebelumnya. Dalam implementasinya, digunakan distribusi Gaussian untuk mengasumsikan penyebaran data, serta parameter `random_state = 42` dan `n_split = 10` pada teknik *k-fold cross-validation* untuk memastikan evaluasi model yang konsisten dan menyeluruh.



Gambar 5. Confusion Matrix *Naïve Bayes*


Pada gambar 5 terlihat bahwa model *Naïve Bayes* dengan menerapkan distribusi Gaussian mampu mengklasifikasikan kategori Low Stress dengan sangat baik, dengan 33 data terprediksi dengan benar. Begitu juga dengan kategori High Stress, di mana model berhasil mengklasifikasikan 18 data dengan benar. Namun, pada kategori medium Stress, hasilnya kurang optimal. Dari total data, hanya 1 yang berhasil diklasifikasikan dengan benar, sementara sisanya salah terdeteksi sebagai kategori lain. Hal ini menunjukkan bahwa model *Naïve Bayes* lebih efektif dalam mengidentifikasi Low stress, tetapi kurang akurat dalam membedakan individu dengan pada tingkat Medium stres. Secara keseluruhan, algoritma *Naïve Bayes* memiliki performa yang cukup baik, tetapi masih perlu ditingkatkan. Kemungkinan besar, hal ini disebabkan oleh distribusi data atau karakteristik fitur yang kurang mendukung pemisahan kategori dengan baik. Optimalisasi fitur atau pendekatan preprocessing yang lebih tepat mungkin dapat meningkatkan akurasi model.

	precision	recall	f1-score	support
0	0.47	0.47	0.47	38
1	0.55	0.92	0.69	36
2	0.50	0.04	0.07	26
accuracy			0.52	100
macro avg	0.51	0.48	0.41	100
weighted avg	0.51	0.52	0.45	100

Gambar 6. Hasil Akurasi *Naïve Bayes*

Pada gambar 6 dapat dilihat tingkat akurasi yang didapatkan sebesar 52%, precision 51%, recall 48%, f1-score 41%. Nilai akurasi ini menunjukkan bahwa model *Naïve Bayes* hanya mampu mengklasifikasikan data dengan hasil sebesar 52% dari seluruh sampel yang diuji.

D. Perbandingan



Gambar 7. Perbandingan kinerja K-Neares Neighbor dan *Naïve Bayes*

Pada Gambar 7 Perbandingan performa metode *K-Nearest Neighbors* dan *Naïve Bayes* dalam klasifikasi tingkat stres menunjukkan bahwa KNN dengan $K = 5$ mampu mencapai akurasi 74%, sedangkan *Naïve Bayes* hanya memperoleh 52%. Hasil ini menegaskan bahwa KNN lebih unggul dalam mengenali pola dan karakteristik data yang berkaitan dengan tingkat stres, sehingga menghasilkan klasifikasi yang lebih akurat. Perbedaan akurasi ini menunjukkan bahwa metode yang digunakan dalam klasifikasi sangat berpengaruh terhadap hasil yang diperoleh, terutama dalam kasus data yang memiliki pola bervariasi.

Hasil ini juga didukung oleh penelitian sebelumnya yang menunjukkan bahwa meskipun jumlah data yang digunakan tidak terlalu banyak, metode *K-Nearest Neighbors* tetap mampu memberikan akurasi yang lebih tinggi dibandingkan dengan *Naïve Bayes*. Keunggulan ini disebabkan oleh cara kerja KNN yang membandingkan data baru dengan data yang sudah ada berdasarkan kedekatan dalam ruang fitur. Dengan pendekatan ini, KNN lebih fleksibel dalam mengenali pola dan tidak memiliki ketergantungan tertentu terhadap karakteristik distribusi data. Hal ini memungkinkan KNN untuk menangkap hubungan kompleks antar fitur, sehingga menghasilkan klasifikasi yang lebih akurat.

Sebaliknya, *Naïve Bayes* menggunakan pendekatan berbasis probabilitas yang bergantung pada pola kemunculan data di masa lalu. Metode ini menganggap bahwa setiap fitur dalam data tidak memiliki ketergantungan satu sama lain. Namun, dalam kasus klasifikasi tingkat stres, hubungan antar fitur tidak bisa diabaikan begitu saja karena faktor-faktor yang mempengaruhi stres sering kali saling berkaitan. Akibatnya,

pendekatan yang digunakan oleh *Naïve Bayes* dapat menyebabkan kesalahan dalam mengenali pola data yang lebih kompleks, sehingga akurasi klasifikasinya lebih rendah dibandingkan dengan KNN.

Dengan melihat hasil evaluasi yang diperoleh, keunggulan KNN dalam mengenali pola data memang sudah terbukti. Metode ini mampu mengklasifikasikan data dengan lebih baik tanpa perlu bergantung pada keterkaitan fitur yang spesifik, menjadikannya lebih unggul dalam menangani variasi dalam data. Oleh karena itu, dalam konteks klasifikasi tingkat stres, pemilihan metode yang tepat sangat berpengaruh terhadap akurasi hasil yang diperoleh, dan dalam hal ini, KNN terbukti lebih efektif dibandingkan *Naïve Bayes*.

IV. SIMPULAN

Berdasarkan hasil penelitian yang menggunakan parameter `random_state = 42` dan `n_splits = 10` pada teknik *k-fold cross-validation*, telah diterapkan dua metode algoritma klasifikasi, yaitu *Naïve Bayes* dan *K-Nearest Neighbors* (KNN), untuk mengklasifikasikan tingkat stres. Hasil evaluasi menunjukkan bahwa algoritma *K-Nearest Neighbors* lebih unggul dibandingkan *Naïve Bayes* dalam mengenali pola data tingkat stres. KNN dengan nilai $K = 5$ berhasil mencapai akurasi sebesar 74%, dengan precision, recall, dan f1-score masing-masing sebesar 73%. Sementara itu, algoritma *Naïve Bayes* hanya memperoleh akurasi sebesar 52%, precision sebesar 51%, recall sebesar 48%, dan f1-score sebesar 41%. Perbedaan performa ini mengindikasikan bahwa KNN lebih efektif dalam mengidentifikasi pola-pola yang berkaitan dengan tingkat stres pada data yang digunakan.

Namun demikian, meskipun KNN menunjukkan performa yang lebih baik, akurasinya masih dapat ditingkatkan. Hal ini disebabkan oleh beberapa keterbatasan dalam penelitian, antara lain jumlah data yang relatif sedikit serta jenis perangkat yang digunakan dalam proses pengambilan data, yang kemungkinan memengaruhi kualitas deteksi. Selain itu, faktor lingkungan seperti pencahayaan saat perekaman data juga berpengaruh terhadap akurasi model. Dalam klasifikasi tingkat stres, kualitas, keragaman data, dan kondisi teknis pengambilan data sangat menentukan performa sistem klasifikasi. Untuk penelitian selanjutnya, disarankan agar jumlah dan variasi data ditingkatkan sehingga model dapat mengenali pola yang lebih kompleks dan mengurangi risiko overfitting. Penggunaan perangkat yang lebih konsisten atau canggih, serta pengendalian kondisi pengambilan data seperti pencahayaan, dapat membantu menghasilkan data yang lebih stabil dan representatif.

Selain itu, optimasi tahapan preprocessing seperti normalisasi data, seleksi fitur yang lebih relevan, atau penerapan teknik *data augmentation* juga dapat meningkatkan kualitas input model. Penelitian lebih lanjut juga dapat mengeksplorasi algoritma klasifikasi lain seperti *Support Vector Machine* (SVM), *Random Forest*, atau metode berbasis *Deep Learning* seperti *Neural Networks*. Penerapan ensemble learning yang menggabungkan beberapa algoritma juga dapat dipertimbangkan untuk meningkatkan akurasi dan daya generalisasi model. Dengan peningkatan kualitas dan kuantitas data, pemilihan perangkat yang sesuai, serta eksplorasi metode yang lebih kompleks, diharapkan klasifikasi tingkat stres dapat dilakukan dengan lebih akurat dan efektif pada penelitian-penelitian berikutnya.

UCAPAN TERIMAKASIH

Ucapan terima kasih kepada program studi Teknik Informatika, Universitas Muhammadiyah Bengkulu atas segala bantuan yang telah diberikan kepada saya selama proses penelitian ini. Penghargaan setinggi tinginya untuk keluarga saya yang telah memberikan dukungan moral dan doa yang tiada henti. Tidak lupa rekan-rekan yang telah memberikan saran dan kontribusi berharaga mereka. Ucapan terima kasih kepada pihak redaksi jurnal yang telah memberikan ruang untuk mempublikasi hasil penelitian saya.

DAFTAR PUSTAKA

- [1] gloriabarus, "Hasil Survei I-NAMHS: Satu dari Tiga Remaja Indonesia Memiliki Masalah Kesehatan Mental."
- [2] Sulis Winurini, "PEMERIKSAAN KESEHATAN MENTAL GRATIS BAGI REMAJA," Feb. 2025.
- [3] F. Vancheri, G. Longo, E. Vancheri, and M. Y. Henein, "Mental Stress and Cardiovascular Health—Part I," Jun. 01, 2022, *MDPI*, doi: 10.3390/jcm11123353.
- [4] R. T. H. Hasan and A. B. Sallow, "Face Detection and Recognition Using OpenCV," *Journal of Soft Computing and Data Mining*, vol. 2, no. 2, pp. 86–97, Oct. 2021, doi: 10.30880/jscdm.2021.02.02.008.
- [5] W. A. M. Sari, B. Suhardi, and I. W. Suletra, "Pengaruh Kondisi Sistem Kerja Terhadap Stress Kerja dengan Menggunakan Macroergonomic Organizational Questionnaire Survey (MOQS)," *Jurnal INTECH Teknik Industri Universitas Serang Raya*, vol. 7, no. 1, pp. 30–38, Apr. 2021, doi: 10.30656/intech.v7i1.2822.
- [6] Naufal Fathirachman Mahing, Alifi Lazuardi Gunawan, Ahmad Foresta Azhar Zen, Fitra Abdurrachman Bachtiar, and Satrio Agung Wicaksono, "KLASIFIKASI TINGKAT STRES DARI DATA BERBENTUK TEKS DENGAN MENGGUNAKAN ALGORITMA SUPPORT VECTOR MACHINE (SVM) DAN RANDOM FOREST," *Jurnal Teknologi Informasi dan Ilmu Komputer (JTIIK)*, 2024, doi: 10.25126/jtiik2024118010.
- [7] Syefrida Yuliana and Warnia Nengsih, "DETEKSI WAJAH MENGGUNAKAN HAAR CASCADE DAN FEATURE DESCRIPTOR HOG MELALUI KAMERA IP CCTV DIRUANG KELAS," *Jurnal Kecerdasan Buatan dan Teknologi Informasi*, vol. 3, no. 2, 2024.

- [8] M Abdy Mulya, Zaenul Arif, and Syefudin, "Tinjauan Pustaka Sistematis : Penerapan Metode Gabor Wavelet Pada Computer Vision," *Journal Of Computer Science And Technology (JOCSTEC)*, vol. 1, no. 2, pp. 83–88, May 2023, doi: 10.59435/jocstec.v1i2.78.
- [9] Andri Nugraha Ramdhon and Fadly Febriya, "Penerapan Face Recognition Pada Sistem Presensi," *Journal of Applied Computer Science and Technology*, vol. 2, no. 1, pp. 12–17, Jun. 2021, doi: 10.52158/jacost.v2i1.121.
- [10] Sugeng and Agus Mulyana, "Sistem Absensi Menggunakan Pengenalan Wajah (Face Recognition) Berbasis Web LAN," *Jurnal Sisfokom (Sistem Informasi dan Komputer)*, vol. 11, no. 1, pp. 127–135, Apr. 2022, doi: 10.32736/sisfokom.v11i1.1371.
- [11] Fitra A. Bachtiar, Muhammad Wafi, and P. Korespondensi, "COMPARISON OF CLASSIFICATION METHODS FOR FACIAL EXPRESSION RECOGNITION USING FACIAL LANDMARK FEATURE," *Jurnal Teknologi Informasi dan Ilmu Komputer (JTIK)*, 2021, doi: 10.25126/jtiik.202184434.
- [12] Rifki Kosasih, "Classification of Banana Ripe Level Based on Texture Features and KNN Algorithms," 2021.
- [13] Berliana Wahyu Nurlita *et al.*, "COMPARISON OF ARCFACE AND DLIB PERFORMANCE IN FACE RECOGNITION WITH DETECTION USING YOLOV8 PERBANDINGAN KINERJA ARCFACE DAN DLIB DALAM PENGENALAN WAJAH DENGAN DETEKSI MENGGUNAKAN YOLOV8," *JURNAL INOVTEK POLBENG*, vol. 9, no. 2, p. 2024, 2024.
- [14] Andi Hakim Arif and Achmad Solichin, "Hyperparameter Optimization on Ensemble Regression Tree for Lip Coloring Simulation," *Jurnal Teknik Informatika dan Sistem Informasi*, vol. 8, no. 2, Aug. 2022, doi: 10.28932/jutisi.v8i2.4611.
- [15] Chandra I. Zamorano, Kiki Prawiroredjo, E. Shintadewi Julian, and Endang Djuana, "Rancang Bangun Sistem Kamera Pengawas dengan Pengenalan Wajah untuk Keamanan Berbasis Blynk Legacy," 2023.
- [16] Rifki Kosasih, "Classification of Banana Ripe Level Based on Texture Features and KNN Algorithms," 2021.
- [17] Nurul A'ayunnisa, Yulita Salim, and Huzain Azis, "Analisis performa metode Gaussian *Naïve Bayes* untuk klasifikasi citra tulisan tangan karakter arab," *Indonesian Journal of Data and Science (IJODAS)*, vol. 3, no. 3, pp. 115–121, 2022.
- [18] Wijiyanto, Afu Ichsan Pradana, Sopingi, and Vihi Athina, "Teknik K-Fold Cross Validation untuk Mengevaluasi Kinerja Mahasiswa," *Jurnal Algoritma*, vol. 21, no. 1, May 2024, doi: 10.33364/algoritma/v.21-1.1618.
- [19] Siti Raysyah, Veri Arinal, and Dadang Iskandar Mulyana, "KLASIFIKASI TINGKAT KEMATANGAN BUAH KOPI BERDASARKAN DETEKSI WARNA MENGGUNAKAN METODE KNN DAN PCA," *Sistem Informasi /*, vol. 8, no. 2, pp. 88–95, 2021.
- [20] Jacqueline M.S. Waworundeng and Raycle Raynold Inzaghi Suwu, "Implementation of Face Recognition in People Monitoring Access In-and-Out of Crystal Dormitory Universitas Klabat Penerapan Face Recognition Pada Pemantauan Orang Dalam Akses Masuk Dan Keluar Asrama Crystal Universitas Klabat," *Cogito Smart Journal /*, vol. 9, no. 1, 2023.
- [21] Nurul A'ayunnisa, Yulita Salim, and Huzain Azis, "Analisis performa metode Gaussian *Naïve Bayes* untuk klasifikasi citra tulisan tangan karakter arab," *Indonesian Journal of Data and Science (IJODAS)*, vol. 3, no. 3, pp. 115–121, 2022.
- [22] Isman, Andani Ahmad, and Abdul Latief, "Perbandingan Metode KNN Dan LBPH Pada Klasifikasi Daun Herbal," *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*, vol. 5, no. 3, pp. 557–564, Jun. 2021, doi: 10.29207/resti.v5i3.3006.